

UNIVERSIDADE DO ESTADO DA BAHIA – UNEB

Departamento de Ciências Exatas e da Terra – Campus I

Tópicos Especiais em Engenharia de Software

Prof. Eduardo Manuel de Freitas Jorge

SPARK

Sistema de Busca de Informações de Pesquisadores
Baseado em Full-Text Search e LLM

Sprint I – Especificação do Projeto

SPK-71: Descrição do Sistema e Especificação de Requisitos
(Histórias do Usuário com Critérios de Aceitação)

Equipe: Calvin Albuquerque
Glenda Santana

Versão: 1.3

Data: 19 de maio de 2026

Salvador, Bahia – 2026

Sumário

1	Introdução	1
2	Descrição do Sistema	1
2.1	Contexto e Motivação	1
2.2	Propósito	1
2.3	Escopo	2
2.4	Sistemas Correlatos	2
2.5	Tecnologias Utilizadas	3
3	Especificação de Requisitos	3
3.1	Metodologia	3
3.2	Atores do Sistema	3
3.3	Histórias do Usuário	5
	US-01 – Busca Textual por Palavras-Chave	5
	US-02 – Busca Semântica por Linguagem Natural	6
	US-03 – Orquestração do ETL dos Dados Lattes	7
4	Casos de Uso	8
4.1	Diagrama de Casos de Uso	8
4.2	Atores	8
4.3	Descrição dos Casos de Uso	9
	UC-01 – Buscar Produções	9
	UC-02 – Filtrar Resultados	10
	UC-03 – Visualizar Detalhes da Produção	11
	UC-04 – Visualizar Perfil do Pesquisador	11
	UC-05 – Gerenciar Pesquisadores	12
5	Projeto Arquitetural	13
5.1	Camada Operacional	13
5.2	Camada Back-End	14
5.3	Camada Front-End	14
5.4	Protocolos de Comunicação	15

6	Esquema do Banco de Dados	16
6.1	Diagrama Entidade-Relacionamento	16
6.2	Descrição das Tabelas	17
6.3	Decisões Técnicas do Modelo	17
7	Rastreabilidade dos Requisitos	18
8	Considerações Finais	18

1 Introdução

Este documento apresenta a especificação do *Search Platform and Research Knowledge*, **SPARK**, um sistema de busca avançada de produções científicas de pesquisadores desenvolvido como Projeto Integrador da disciplina de Tópicos Especiais em Engenharia de Software da Universidade do Estado da Bahia (UNEB).

O documento está organizado em duas seções principais: a **Descrição do Sistema**, que contextualiza o problema, os objetivos e a solução proposta; e a **Especificação de Requisitos**, que apresenta as funcionalidades do sistema na forma de Histórias do Usuário com seus respectivos Critérios de Aceitação.

2 Descrição do Sistema

2.1 Contexto e Motivação

As universidades brasileiras produzem um volume significativo de pesquisa científica, registrada nos currículos Lattes de seus pesquisadores. No entanto, a ausência de ferramentas de busca semântica e contextual dificulta o mapeamento de competências, a identificação de colaboradores e a análise de tendências de pesquisa institucionais.

O sistema SPARK surge para atender a essa necessidade no contexto da UNEB, oferecendo uma plataforma que centraliza e torna navegável a produção científica dos pesquisadores de forma inteligente.

2.2 Propósito

O SPARK tem como propósito principal orquestrar o processo de **ETL** (Extração, Transformação e Carga) dos dados dos currículos Lattes – disponíveis em formato XML – para uma base de dados relacional, enriquecendo as informações com dados bibliométricos externos (Qualis CAPES, Fator de Impacto JCR e DOI).

Sobre essa base estruturada, o sistema disponibiliza duas modalidades de busca:

- **Busca textual (Full-Text Search):** baseada em indexação nativa do PostgreSQL via `tsvector`, permitindo buscas por palavras-chave com suporte a operadores bo-

oleanos.

- **Busca semântica:** baseada em vetores matemáticos (*embeddings*) gerados pelo modelo local **Sentence-Transformers** (`all-MiniLM-L6-v2`), armazenados via extensão `pgvector` no Supabase, possibilitando encontrar produções por contexto e significado.

2.3 Escopo

O sistema SPARK abrange os seguintes módulos:

1. **Camada Operacional (ETL):** pipeline Apache Hop para leitura, transformação e carga dos XMLs do Lattes no banco de dados relacional, incluindo integração com bases externas (Qualis CAPES, JCR, DOI e resumo via CrossRef).
2. **Camada de Back-End:** API RESTful desenvolvida em Python com FastAPI, hospedada no Railway, responsável pelas regras de negócio e geração de *embeddings* via modelo local Sentence-Transformers (`all-MiniLM-L6-v2`).
3. **Camada de Banco de Dados:** Supabase (PostgreSQL gerenciado) com a extensão `pgvector` habilitada, responsável pelo armazenamento relacional e vetorial.
4. **Camada de Front-End:** aplicação web desenvolvida em Next.js, hospedada no Vercel, que consome a API REST para exibir os resultados de busca em interface responsiva com indicadores Qualis e JCR.

2.4 Sistemas Correlatos

Para embasar o projeto, foram analisados sistemas com objetivos similares:

Tabela 1: Sistemas correlatos ao SPARK

Sistema	Descrição
SIMCC (UESC)	Sistema de Mapeamento de Competências da Bahia, disponível em simcc.uesc.br .
SOMOS (UFMG)	Sistema de mapeamento de competências da UFMG para incrementar a interação com instituições públicas e privadas, disponível em somos.ufmg.br .

2.5 Tecnologias Utilizadas

Tabela 2: Tecnologias e ferramentas do projeto SPARK

Camada	Tecnologia	Finalidade
Orquestração	Apache Hop	Pipeline ETL dos XMLs do Lattes
Banco de Dados	Supabase	PostgreSQL gerenciado com pgvector
Back-End	Python / FastAPI	API RESTful e lógica de negócios
Back-End	Railway	Hospedagem gratuita do back-end
IA / LLM	Sentence-Transformers	Geração de embeddings (modelo local <code>all-MiniLM-L6-v2</code>)
Front-End	Next.js	Interface de busca e visualização
Front-End	Vercel	Hospedagem gratuita do front-end
Versionamento	Git / GitHub	Controle de versão do código
Containerização	Docker	Ambiente de desenvolvimento local

3 Especificação de Requisitos

3.1 Metodologia

Os requisitos foram levantados e documentados no formato de **Histórias do Usuário** (*User Stories*), conforme a metodologia ágil Scrum adotada no projeto. Cada história segue a estrutura:

“Como [ator], quero [funcionalidade], para [objetivo/valor].”

Cada história possui **Critérios de Aceitação** mensuráveis que definem quando a funcionalidade está concluída, e uma **Definição de Pronto** (DoD) que estabelece os requisitos de qualidade e entrega.

3.2 Atores do Sistema

- **Usuário:** pesquisador, gestor ou qualquer pessoa que utiliza a interface web para buscar produções científicas. O acesso é público e não requer autenticação.

- **Engenheiro de Dados:** responsável pela orquestração do pipeline de ETL via Apache Hop.

3.3 Histórias do Usuário

US-01 Busca Textual por Palavras-Chave

US-01 – Busca Textual por Palavras-Chave	
Como	Usuário do sistema
Quero	Buscar produções científicas por palavras-chave
Para	Encontrar artigos e produções que contenham os termos pesquisados no título
Critérios de Aceitação	
CA-01.1	O sistema deve retornar resultados que contenham as palavras-chave no título da produção.
CA-01.2	A busca deve suportar operadores básicos de Full-Text Search (AND, OR, NOT) via índice <code>tsvector</code> do PostgreSQL.
CA-01.3	Os resultados devem ser paginados, exibindo no máximo 20 itens por página.
CA-01.4	O tempo de resposta da API deve ser inferior a 30 segundos.
CA-01.5	Cada resultado deve exibir: título, nome do veículo, ano de publicação, estrato Qualis e Fator de Impacto JCR (quando disponíveis).
Definição de Pronto (DoD)	
DoD	Código no Git com commit referenciando esta issue; endpoint <code>POST /api/search/text</code> funcional e documentado no Swagger; testes unitários passando; demonstrado na Sprint Review.

US-02 Busca Semântica por Linguagem Natural

US-02 – Busca Semântica por Linguagem Natural

Como Usuário do sistema

Quero Realizar buscas usando linguagem natural

Para Encontrar produções cujo contexto e significado correspondam à minha pesquisa, sem precisar usar palavras exatas

Critérios de Aceitação

CA-02.1 O sistema deve converter a consulta do usuário em vetor (*embedding*) usando o modelo local Sentence-Transformers (`all-MiniLM-L6-v2`).

CA-02.2 O sistema deve calcular a similaridade de cosseno via `pgvector` no Supabase e retornar os resultados mais similares ranqueados no topo.

CA-02.3 O *score* de similaridade deve ser visível na resposta JSON e exibido na interface.

CA-02.4 O tempo de resposta deve ser inferior a 5 segundos.

CA-02.5 Testes unitários devem validar a geração de embeddings e o ranqueamento por similaridade.

Definição de Pronto (DoD)

DoD Código no Git com commit referenciando esta issue; endpoint `POST /api/search/semantic` funcional e documentado no Swagger; testes unitários passando; tempo de resposta validado; demonstrado na Sprint Review.

US-03 Orquestração do ETL dos Dados Lattes

US-03 – Orquestração do ETL dos Dados Lattes

Como Engenheiro de Dados

Quero Orquestrar a extração e carga dos dados dos currículos Lattes em formato XML via Apache Hop

Para Popular o banco de dados relacional no Supabase com as informações dos pesquisadores e suas produções científicas

Critérios de Aceitação

CA-03.1 O pipeline Hop deve ler diretórios contendo arquivos XML do Lattes.

CA-03.2 As tags de Pesquisador e Produções devem ser mapeadas e inseridas nas respectivas tabelas do banco.

CA-03.3 O pipeline deve realizar UPSERT (inserção ou atualização) para evitar duplicações.

CA-03.4 Após a carga, o pipeline deve integrar os dados com bases externas: Qualis CAPES (por ISSN/nome do veículo), DOI, resumo e Fator de Impacto JCR.

CA-03.5 O pipeline deve gerar um log com os registros que não obtiveram correspondência nas bases externas.

CA-03.6 Ao final de cada carga, o pipeline deve atualizar as métricas bibliométricas pré-calculadas de cada pesquisador processado (total de produções, índice H e total A1+A2).

CA-03.7 O pipeline deve ser testado com no mínimo 10 currículos reais.

Definição de Pronto (DoD)

DoD Código do pipeline no Git com README de instalação e execução; executado com sucesso com 10 currículos reais; demonstrado na Sprint Review.

4 Casos de Uso

4.1 Diagrama de Casos de Uso

O diagrama abaixo representa as interações dos atores com o sistema SPARK do ponto de vista do usuário final.




Figura 1: Diagrama de Casos de Uso do sistema SPARK

4.2 Atores

Tabela 3: Atores do sistema SPARK

Ator	Descrição
Usuário	Pesquisador, gestor ou qualquer pessoa que acessa a interface web para realizar buscas e navegar pelas produções científicas. O acesso é integralmente público — nenhuma funcionalidade do Usuário requer autenticação.
Admin	Usuário com permissões elevadas, responsável por gerenciar os pesquisadores cadastrados no sistema. Herda todas as ações do Usuário.

4.3 Descrição dos Casos de Uso

UC-01 Buscar Produções

UC-01 – Buscar Produções	
Ator Principal	Usuário
Pré-condição	O banco de dados deve estar populado com ao menos uma produção científica.
Pós-condição	O usuário visualiza uma lista paginada de produções ordenadas por relevância.
Fluxo Principal	
1	O usuário acessa a interface web e digita um termo ou pergunta na barra de busca.
2	O usuário seleciona o modo de busca: Textual (por palavras-chave) ou Semântico (por linguagem natural).
3	O usuário aciona a busca.
4	O sistema processa a consulta e retorna os resultados em cards, exibindo título, veículo, ano, estrato Qualis e Fator de Impacto JCR de cada produção.
Fluxo de Exceção E1 – Nenhum resultado	
4e	O sistema exibe a mensagem “Nenhuma produção encontrada para a sua busca.” e sugere termos alternativos.
Extensões	
UC-02 (Filtrar Resultados) e UC-03 (Visualizar Detalhes da Produção) podem ser acionados a partir deste caso de uso.	

UC-02 Filtrar Resultados

UC-02 – Filtrar Resultados		«extend» UC-01
Ator Principal	Usuário	
Pré-condição	UC-01 deve ter sido executado e retornado resultados.	
Pós-condição	Os resultados são reapresentados conforme os critérios selecionados.	
Fluxo Principal		
1	O usuário seleciona um ou mais filtros disponíveis: ano de publicação, estrato Qualis, faixa de Fator de Impacto JCR ou área do conhecimento.	
2	O sistema aplica os filtros e atualiza a listagem de resultados sem recarregar a página.	
Fluxo de Exceção E1 – Nenhum resultado após filtro		
2e	O sistema exibe a mensagem “Nenhuma produção encontrada com os filtros selecionados.”	

UC-03 Visualizar Detalhes da Produção

UC-03 – Visualizar Detalhes da Produção		«extend» UC-01
Ator Principal	Usuário	
Pré-condição	A produção deve estar cadastrada no banco.	
Pós-condição	O usuário visualiza todas as informações disponíveis sobre a produção selecionada.	
Fluxo Principal		
1	O usuário clica em um card de produção na lista de resultados.	
2	O sistema exibe: título completo, resumo (quando disponível), ano, nome do veículo, DOI (como link externo), estrato Qualis, Fator de Impacto JCR e nome do pesquisador responsável.	
Extensões		
	UC-04 (Visualizar Perfil do Pesquisador) pode ser acionado a partir deste caso de uso.	

UC-04 Visualizar Perfil do Pesquisador

UC-04 – Visualizar Perfil do Pesquisador		«extend» UC-03
Ator Principal	Usuário	
Pré-condição	O pesquisador deve estar cadastrado no banco.	
Pós-condição	O usuário visualiza o perfil completo do pesquisador com suas produções.	
Fluxo Principal		
1	O usuário clica no nome do pesquisador na página de detalhes de uma produção.	
2	O sistema exibe: nome completo, departamento, campus, resumo do currículo Lattes, total de produções, índice H, total de produções A1+A2, distribuição por estrato Qualis e lista paginada de todas as produções do pesquisador.	

UC-05 Gerenciar Pesquisadores

UC-05 – Gerenciar Pesquisadores

Ator Principal Admin

Pré-condição O Admin deve estar autenticado no sistema.

Pós-condição O pesquisador é cadastrado, atualizado ou removido do banco de dados.

Fluxo Principal – Cadastrar

- 1 O Admin acessa o painel administrativo.
- 2 O Admin preenche o formulário com os dados do pesquisador (nome completo e identificador Lattes).
- 3 O sistema valida e persiste o pesquisador no banco de dados.

Fluxo Alternativo A – Editar

- 2a O Admin seleciona um pesquisador existente, edita os dados e confirma a atualização.

Fluxo Alternativo B – Remover

- 2b O Admin seleciona um pesquisador e confirma a remoção. O sistema remove o pesquisador e todas as suas produções e vetores associados.

Fluxo Alternativo C – Importar XML

- 1c O Admin acessa o painel administrativo e clica em *Importar XML*.
- 2c O Admin seleciona um ou mais arquivos XML de currículos Lattes.
- 3c O sistema encaminha os arquivos ao endpoint interno do Worker ETL (POST /internal/trigger-etl), que executa o mesmo pipeline do Apache Hop: extração, enriquecimento, carga e atualização de métricas.
- 4c O sistema exibe o resultado da importação com o total de pesquisadores e produções inseridos ou atualizados.

Nota sobre papéis

O Engenheiro de Dados opera o pipeline diretamente via Apache Hop (fora da interface web), com acesso ao servidor e às variáveis de ambiente. O Admin pode iniciar o mesmo processo pela interface web via importação de XML, que delega a execução ao Worker ETL

5 Projeto Arquitetural

A arquitetura do sistema SPARK é dividida em três camadas independentes e desacopladas, comunicando-se através de protocolos padrão. `SPK-73_arquitetura.puml`.




Figura 2: Diagrama Arquitetural do sistema SPARK

5.1 Camada Operacional

Responsável pela extração, transformação e carga dos dados brutos. É composta pelo repositório de arquivos XML dos currículos Lattes e pela ferramenta de orquestração **Apache Hop**. O pipeline ETL executa as seguintes etapas:

1. Leitura dos arquivos XML do Lattes do diretório configurado.
2. Transformação e higienização dos dados (nós XML para colunas relacionais, remoção de anomalias e padronização de tipos).
3. Enriquecimento com bases externas:

- **Qualis CAPES** (planilha CSV oficial): classificação dos periódicos por estrato

(A1, A2, A3, A4, B1, B2...) via ISSN ou nome do veículo.

- **CrossRef** (API): obtenção do DOI a partir do título (quando ausente no XML) e do resumo do artigo via campo `abstract` (quando disponível; caso contrário, `producoes.resumo` fica NULL).
 - **OpenAlex** (API): Fator de Impacto do periódico via ISSN (`2yr_mean_citedness`).
4. Carga via UPSERT nas tabelas `pesquisadores` e `producoes` do Supabase.
 5. Atualização das métricas bibliométricas pré-calculadas de cada pesquisador processado na execução: `total_producoes`, `indice_h` e `total_a1_a2`. O índice H é calculado ordenando as produções do pesquisador pelo JCR de forma decrescente e encontrando o maior N tal que N produções possuem $JCR \geq N$.
 6. Acionamento automático do Worker de geração de embeddings ao término da carga.

5.2 Camada Back-End

Hospedada no **Railway**, é o núcleo do sistema. Composta por:

- **Supabase (PostgreSQL + pgvector)**: banco de dados gerenciado que armazena tanto os dados relacionais quanto os vetores de alta dimensionalidade (*embeddings*) das produções científicas.
- **FastAPI (Python)**: API RESTful que gerencia as regras de negócio, expõe os endpoints de busca textual (POST `/api/search/text`) e busca semântica (POST `/api/search/semantic`), e serve a camada de front-end.
- **Worker de Embeddings**: script Python acionado após cada carga ETL que identifica produções sem vetores e gera seus *embeddings* via **Sentence-Transformers** com o modelo local `all-MiniLM-L6-v2`, sem dependência de APIs pagas.

5.3 Camada Front-End

Responsável pela interação e visualização dos dados. Composta por:

- **Next.js (Vercel)**: aplicação web moderna com renderização do lado do servidor que consome a API REST da camada back-end via JSON e exibe os resultados de busca em cards responsivos com indicadores Qualis e JCR.

5.4 Protocolos de Comunicação

Tabela 4: Protocolos de comunicação entre as camadas

Origem	Destino	Protocolo / Formato
Apache Hop	Supabase	Conexão direta PostgreSQL (JDBC)
Apache Hop	CrossRef / OpenAlex	HTTPS / REST JSON
FastAPI	Supabase	Conexão direta PostgreSQL (asyncpg)
FastAPI	Sentence-Transformers	Chamada local (Python)
Next.js	FastAPI	HTTPS / REST JSON

6 Esquema do Banco de Dados

O banco de dados do sistema SPARK é hospedado no **Supabase** (PostgreSQL gerenciado) com a extensão **pgvector** habilitada. O modelo é composto por 6 tabelas: **auth.users** (gerenciada internamente pelo Supabase Auth, exclusivamente para o Admin), **perfis**, **pesquisadores**, **producoes**, **vetores** e **etl_logs**.

6.1 Diagrama Entidade-Relacionamento




Figura 3: Diagrama Entidade-Relacionamento do sistema SPARK

6.2 Descrição das Tabelas

Tabela 5: Tabelas do banco de dados SPARK

Tabela	Descrição
<code>auth.users</code>	Gerenciada pelo Supabase Auth. Armazena e-mail, senha (hash) e metadados de autenticação. Usada exclusivamente para o papel <code>admin</code> nesta versão.
<code>perfis</code>	Estende o <code>auth.users</code> com o papel do usuário no sistema (<code>usuario</code> ou <code>admin</code>) e nome de exibição.
<code>pesquisadores</code>	Dados dos pesquisadores extraídos do currículo Lattes: nome completo, identificador Lattes, departamento, campus, resumo do currículo e métricas bibliométricas pré-calculadas (<code>total_producoes</code> , <code>indice_h</code> , <code>total_a1_a2</code>). As métricas são atualizadas automaticamente ao final de cada execução do pipeline ETL.
<code>producoes</code>	Produções científicas dos pesquisadores com título, tipo, ano, veículo, ISSN, DOI, resumo (obtido via CrossRef quando disponível), estrato Qualis, Fator de Impacto JCR e coluna <code>tsvector</code> para Full-Text Search.
<code>vetores</code>	Embeddings vetoriais das produções gerados pelo modelo local <code>all-MiniLM-L6-v2</code> (Sentence-Transformers), armazenados como <code>vector(384)</code> via extensão <code>pgvector</code> para busca semântica por similaridade de cosseno.
<code>etl_logs</code>	Histórico de execuções do pipeline ETL com status, totais de registros inseridos, atualizados e sem correspondência, e detalhes em formato JSONB.

6.3 Decisões Técnicas do Modelo

- **tsvector com trigger:** a coluna `texto_busca` na tabela `producoes` é populada automaticamente por um trigger a cada inserção ou atualização, garantindo que o índice GIN de Full-Text Search esteja sempre atualizado sem intervenção manual.

- **IVFFlat para busca vetorial:** o índice `ivfflat` com `vector_cosine_ops` na tabela `vetores` permite buscas por similaridade de cosseno com alta performance, mesmo com grande volume de produções.
- **Métricas pré-calculadas no pesquisador:** os campos `total_producoes`, `indice_h` e `total_a1_a2` são calculados e persistidos ao final de cada execução do pipeline ETL, evitando agregações custosas em tempo de consulta. Como o banco só é alterado quando o ETL roda, os valores nunca ficam desatualizados.
- **Row Level Security (RLS):** todas as tabelas possuem RLS habilitado. Produções e pesquisadores têm leitura pública (sem autenticação). Logs do ETL são restritos ao papel `admin`.
- **JSONB para flexibilidade:** o campo `detalhes` (`etl_logs`) usa JSONB para armazenar dados semi-estruturados sem necessidade de migrações de schema a cada evolução do sistema.

7 Rastreabilidade dos Requisitos

A tabela a seguir relaciona cada História do Usuário com o Sprint em que será implementada, conforme o planejamento do projeto.

Tabela 6: Rastreabilidade entre Histórias do Usuário e Sprints

ID	Sprint	Descrição	Prioridade
US-01	Sprint III	Busca textual (Full-Text Search)	Alta
US-02	Sprint III	Busca semântica via pgvector	Alta
US-03	Sprint II	ETL dos dados Lattes via Apache Hop	Alta

8 Considerações Finais

Este documento constitui a base de especificação do Sprint I do projeto SPARK e deverá ser atualizado a cada Sprint Review conforme o professor valide ou solicite ajustes nos requisitos. Todos os artefatos produzidos serão versionados no repositório Git da equipe, com commits referenciando as respectivas issues do Jira (projeto SPARK).